

Министерство науки и высшего образования Российской
Федерации
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО
ОБРАЗОВАНИЯ «НАЦИОНАЛЬНЫЙ
ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ ИТМО»
(УНИВЕРСИТЕТ ИТМО)

ОТЧЕТ О ЛАБОРАТОРНОЙ РАБОТЕ №1

По дисциплине
«Математическая Статистика»

Студенты:
Охрименко Ева
Даниил Буцкий

Проверил:
Шкваренко Андрей Алексеевич

г. Санкт-Петербург
2025

Оглавление

1	Задание 1	2
1.1	Выбор распределения и параметров	2
1.2	Генерация выборок	2
1.3	Вычисление выборочных статистик	3
1.4	Построение гистограмм и наложение теоретической плотности . .	4
1.5	Проверка сходимости $nF(X_{(2)})$ и $n(1 - F(X_{(n)}))$	7
1.6	Вывод статистик	10
2	Задание 2	12
2.1	Первые три вопроса	12
2.2	Написание остальных функций	13
2.3	Выводы по написанным функциям	15

Глава 1

Задание 1

1.1 Выбор распределения и параметров

Выбираем распределение, у которого существуют первые четыре момента. В нашем случае это нормальное распределение.

μ (мю) определяет центр нормального распределения на числовой оси. Это точка, вокруг которой группируются значения.

σ (сигма) определяет "ширину" нормального распределения, то есть, насколько разбросаны значения относительно μ .

```
# Параметры распределения
```

```
mu = 0          # Центр нормального распределения
```

```
sigma = 1       # Стандартное отклонение
```

1.2 Генерация выборок

Генерируем достаточно большое количество выборок достаточно большого объема из выбранного распределения.

```
# Параметры генерации выборок
```

```
M = 10000      # Количество выборок
```

```
n = 1000       # Размер выборки
```

```
# Генерация выборок из нормального распределения
```

```
samples = np.random.normal(mu, sigma, size=(M, n))
```

Пояснение:

- M : Определяет, сколько раз мы будем повторять эксперимент (генерировать выборку и вычислять статистики).

- n : Определяет размер каждой выборки.
- `np.random.normal(mu, sigma, size=(M, n))`: Генерирует M выборок размером n из нормального распределения с параметрами μ и σ .

1.3 Вычисление выборочных статистик

Для каждой сгенерированной выборки вычисляем соответствующие статистики: выборочное среднее, выборочную дисперсию и выборочную медиану.

```
# Вычисление статистик для каждой выборки
means = np.mean(samples, axis=1)          # Выборочные средние
variances = np.var(samples, axis=1, ddof=1) # Выборочные дисперсии
medians = np.median(samples, axis=1)      # Медианы
```

Выборочное среднее \bar{X} — это среднее значение выборки X_1, X_2, \dots, X_n , вычисляемое по формуле:

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i.$$

Выборочная дисперсия S^2 — это мера разброса значений выборки относительно выборочного среднего. Несмещенная оценка выборочной дисперсии вычисляется по формуле:

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2.$$

Квантиль порядка p — это значение, которое случайная величина не превышает с вероятностью p . Квантиль порядка 0.5 называется медианой и является серединным значением в упорядоченной выборке.

Пояснение:

- `np.mean(samples, axis=1)`: Вычисляет выборочное среднее для каждой выборки (среднее по строкам матрицы `samples`).
- `np.var(samples, axis=1, ddof=1)`: Вычисляет выборочную дисперсию для каждой выборки. `ddof=1` обеспечивает несмещенную оценку дисперсии.
- `np.median(samples, axis=1)`: Вычисляет медиану для каждой выборки.

1.4 Построение гистограмм и наложение теоретической плотности

Строим гистограммы результатов для каждой выборочной статистики. Для наглядности рядом с гистограммой рисуем соответствующую теоретическую плотность.

Асимптотическая нормальность означает, что при увеличении размера выборки ($n \rightarrow \infty$), распределение выборочной статистики сходится к нормальному распределению. Это важный результат, позволяющий использовать свойства нормального распределения для анализа статистик при больших выборках.

```
# Функция для построения гистограмм и наложения теоретической плотности
def plot_histogram(data, theoretical_dist, params, title):
    plt.hist(data, bins=30, density=True, alpha=0.6, color='blue', label='Гистограмма')
    x = np.linspace(min(data), max(data), 100)
    pdf = theoretical_dist.pdf(x, *params)
    plt.plot(x, pdf, 'r-', label='Теоретическая плотность')
    plt.legend()
    plt.title(title)
    plt.show()

# Гистограмма для выборочного среднего
plot_histogram(
    means,
    norm,
    (mu, sigma / np.sqrt(n)),
    'Выборочное среднее'
)

# Гистограмма для выборочной дисперсии
plot_histogram(
    variances,
    norm,
    (mu, sigma / np.sqrt(n)),
    'Выборочная дисперсия'
)

# Гистограмма для медианы
plot_histogram(
    medians,
```

```
norm,
(mu, sigma / np.sqrt(n)),
'Медиана'
)
```



Рис. 1.1: Выборочное среднее




Рис. 1.2: Выборочная дисперсия

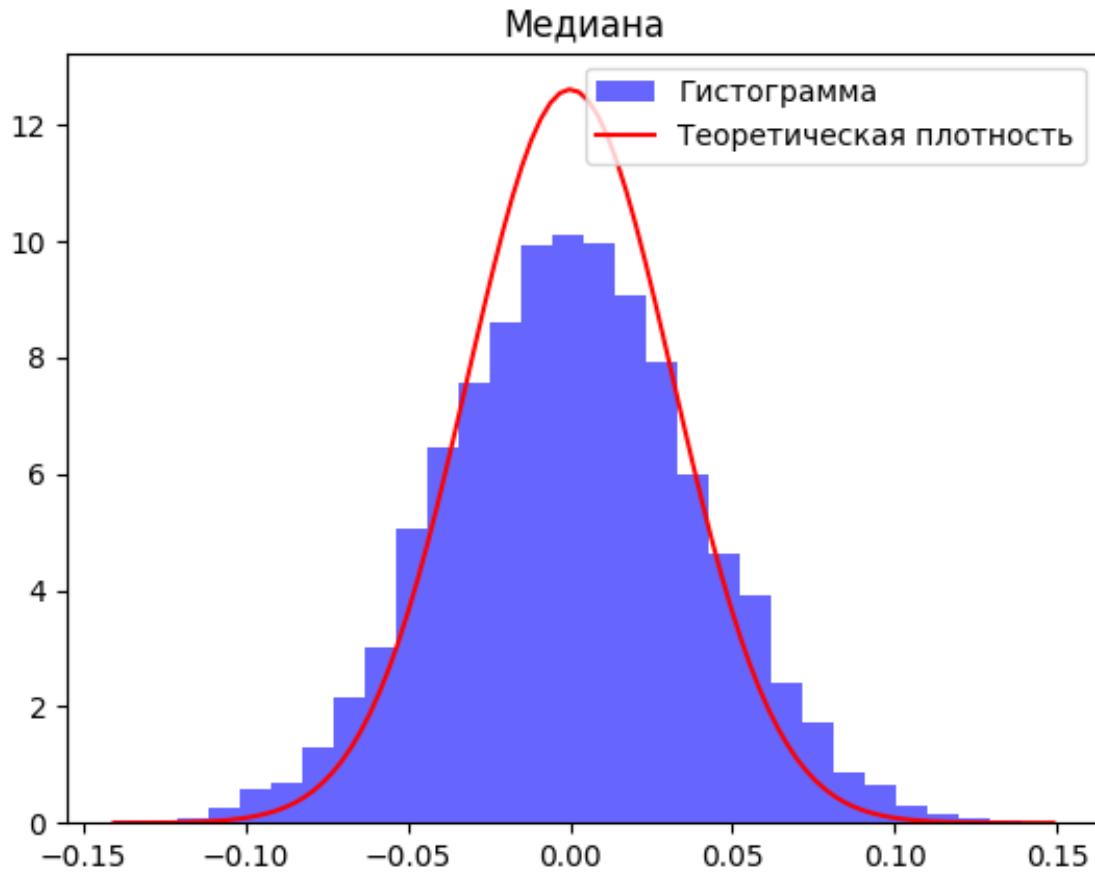


Рис. 1.3: Медиана

1.5 Проверка сходимости $nF(X_{(2)})$ и $n(1 - F(X_{(n)}))$

Экспериментально убеждаемся в том, что $nF(X_{(2)}) \rightarrow \Gamma(2, 1)$ и $n(1 - F(X_{(n)})) \rightarrow \Gamma(1, 1) = \text{Exp}(1)$.

```
# Проверка утверждений о U1 и U2
sorted_samples = np.sort(samples, axis=1)
X_2 = sorted_samples[:, 1]          # Второй элемент в каждой выборке
X_n = sorted_samples[:, -1]        # Максимальный элемент в каждой выборке

# Вычисление F(X) с помощью функции распределения нормального закона
F_X_2 = norm.cdf(X_2, loc=mu, scale=sigma)
F_X_n = norm.cdf(X_n, loc=mu, scale=sigma)

# Сходимость величин U_1 и U_2
U_1 = n * F_X_2                    # nF(X_(2))
```



```

U_2 = n * (1 - F_X_n)          # n(1 - F(X_(n)))

# Гистограмма для U_1 (Gamma(2, 1))
plot_histogram(
    U_1,
    gamma,
    (2,), # Параметры гамма-распределения: shape=2
    'Сходимость U_1 к Gamma(2, 1)'
)

# Гистограмма для U_2 (Exp(1))
plot_histogram(
    U_2,
    expon,
    (), # Параметры экспоненциального распределения: scale=1
    'Сходимость U_2 к Exp(1)'
)

```




Рис. 1.4: Сходимость U_1




Рис. 1.5: Сходимость U_2

1.6 Вывод статистик

Выводим математическое ожидание и дисперсию каждой выборочной статистики для проверки согласованности с законом распределения.

```
# Вывод статистик
print("Мат. ожидание выборочного среднего:", np.mean(means))
print("Дисперсия выборочного среднего:", np.var(means))
print("Мат. ожидание выборочной дисперсии:", np.mean(variances))
print("Дисперсия выборочной дисперсии:", np.var(variances))
print("Мат. ожидание медианы:", np.mean(medians))
print("Дисперсия медианы:", np.var(medians))
print("Мат. ожидание U1:", np.mean(U_1))
print("Дисперсия U1:", np.var(U_1))
print("Мат. ожидание U2:", np.mean(U_2))
print("Дисперсия U2:", np.var(U_2))
```

```
C:\Users\danya\pythonProject5\venv\Scripts\python.exe C:/Users/danya/pythonProject5/lab1_ecology.py
Мат. ожидание выборочного среднего: 9.792179288167335e-05
Дисперсия выборочного среднего: 0.0009864984960822687
Мат. ожидание выборочной дисперсии: 0.9992560052569941
Дисперсия выборочной дисперсии: 0.0020091234399176694
Мат. ожидание медианы: 0.0003860425661529306
Дисперсия медианы: 0.0015455170809012667
Мат. ожидание U1: 2.011104631499844
Дисперсия U1: 2.0331557575298094
Мат. ожидание U2: 0.9948323976908734
Дисперсия U2: 0.9769825775643112

Process finished with exit code 0
```

Рис. 1.6: Вывод статистик

Глава 2

Задание 2

2.1 Первые три вопроса

В этом задании нашей команде нужно было сделать 4 вариант. Итак, для начала ответим на первые простые 3 вопроса: "Сколько моделей телефонов можно вставить 2 сим-карты, сколько поддерживают 3G, каково наибольшее число ядер у процессора?". Для этого напомним код, который открывает наш файл и все считывает:

```
1 file = open("/home/evaДокументы//ITM0/2_course/MatStat/lab1/mobile_phones.csv")
2
3 counter = 0
4 data = list()
5
6 counterDualSim = 0
7 counterTreeG = 0
8 maxNCores = -100500
9
10 for str in file:
11     counter += 1
12     if counter != 1:
13         row = (list(map(float, str.split(','))))
14         data.append(row)
15
16         if row[3] == True:
17             counterDualSim += 1
18         if row[-4] == True:
19             counterTreeG += 1
20         if row[9] > maxNCores:
21             maxNCores = row[9]
22
23 print(counterDualSim, " - столько телефонов поддерживают 2 симкарты-")
24 print(counterTreeG, " - столько телефонов имеют 3G")
25 print(int(maxNCores), "- максимальное число ядер процессора")
```

Листинг 2.1: Код для первых трех вопросов

Этот код в цикле вычленяет определенные значения и инкрементирует опре-

деленные `counter`. Также он ищет максимальное число ядер процессора. Посмотрим на вывод:

```
1 1019 - столько телефонов поддерживают 2 симкарты-
2 1523 - столько телефонов имеют 3G
3 8 - максимальное число ядер процессора
```

Листинг 2.2: Вывод для первых трех вопросов

2.2 Написание остальных функций

Далее по заданию нужно рассчитать несколько параметров для наших выборок. Выборки - это 3 массива данных, в них будет содержаться информация о емкости аккумулятора для всей совокупности, для телефонов, поддерживающих Wi-Fi и для телефонов, не поддерживающих Wi-Fi. Упустим то, как мы из двумерного массива нашли 3 нам подходящих и перейдем к написанию функций:

Функция выборочного среднего

1 функция - функция выборочного среднего. Мы ее находили по формуле:

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n x_i$$

```
1 def calculateMean(data):
2     return sum(data) / len(data)
```

Листинг 2.3: Функция поиска выборочного среднего

Выборочная дисперсия

Эту функцию мы считали по формуле:

$$\sigma^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{X})^2$$

```
1 def calculateVariance(data):
2     mean = calculateMean(data)
3     return sum((x - mean) ** 2 for x in data) / (len(data) - 1)
```

Листинг 2.4: Функция поиска выборочной дисперсии

Выборочная медиана

Ее мы считали по формуле:

$$E = \begin{cases} x_k, & \text{если } n \text{ нечётное,} \\ \frac{x_k + x_{k+1}}{2}, & \text{если } n \text{ чётное,} \end{cases}$$

где $k = \lfloor \frac{n}{2} \rfloor + 1$.

```
1 def calculateMedian(data):
2     sortedData = sorted(data)
3     n = len(sortedData)
4     if n % 2 == 1:
5         return sortedData[n // 2]
6     else:
7         return (sortedData[n // 2 - 1] + sortedData[n // 2]) / 2
```

Листинг 2.5: Функция поиска выборочной медианы

Выборочный квантиль порядка $\frac{2}{5}$

$$Q_p = x_{[i]} + (i - [i]) \cdot (x_{[i]+1} - x_{[i]}),$$

где $i = p \cdot (n - 1)$.

```
1 def calculateQuantile(data, p):
2     sortedData = sorted(data)
3     n = len(sortedData)
4     index = p * (n - 1)
5     lowerIndex = int(index)
6     fraction = index - lowerIndex
7     if lowerIndex + 1 < n:
8         return sortedData[lowerIndex] + fraction * (sortedData[lowerIndex + 1]
9         - sortedData[lowerIndex])
10    return sortedData[lowerIndex]
```

Листинг 2.6: Функция поиска выборочного квантиля порядка $\frac{2}{5}$

Графики

А также мы построим для наших выборок графики эмпирической функции распределения, гистограмму и box-plot (в одной функции, чтобы все графики поместились на одной фигуре).

```
1 def plots(data, title="Графики распределения"):
2
3     fig, axes = plt.subplots(1, 3, figsize=(18, 6))
4     fig.suptitle(title, fontsize=16)
5
6     sorted_data = sorted(data)
7     n = len(sorted_data)
```

```

8     x_values = sorted_data
9     y_values = [i / n for i in range(1, n + 1)]
10
11     axes[0].step(x_values, y_values, where='post', label='ЭФ', color='red',
12 linewidth=2.5)
13     axes[0].set_xlabel('Значения', fontsize=12)
14     axes[0].set_ylabel('F(x)', fontsize=12)
15     axes[0].set_title('Эмпирическая функция распределения', fontsize=14)
16     axes[0].legend(fontsize=10)
17     axes[0].grid(True)
18
19     axes[1].hist(data, bins=30, color='blue', edgecolor='black', linewidth=1.5)
20     axes[1].set_xlabel('Значения', fontsize=12)
21     axes[1].set_ylabel('Частота', fontsize=12)
22     axes[1].set_title('Гистограмма', fontsize=14)
23     axes[1].grid(True)
24
25     axes[2].boxplot(data, vert=True, patch_artist=True, boxprops=dict(facecolor
26 = "lightblue"))
27     axes[2].set_ylabel('Значения', fontsize=12)
28     axes[2].set_title('Box-plot', fontsize=14)
29     axes[2].grid(True)
30
31     plt.tight_layout()
32     plt.show()

```

Листинг 2.7: Графики распределения

2.3 Выводы по написанным функциям

Итак теперь посмотрим, что выведет наш код для разных выборок:

Выводы по емкости аккумулятора для всех телефонов

```

1 1238.5185 - выборочное среднее
2 193088.35983766866 - выборочная дисперсия
3 1226.0 - выборочная медиана
4 1076.0 - выборочная квантиль порядка 2/5

```

Листинг 2.8: Вывод 1




Рис. 2.1: Графики 1

Выводы по емкости аккумулятора для телефонов с Wi-Fi

```

1 1234.9043392504932 - выборочное среднее
2 190296.40051422257 - выборочная дисперсия
3 1233.0 - выборочная медиана
4 1077.8000000000002 - выборочная квантиль порядка 2/5

```

Листинг 2.9: Вывод 2




Рис. 2.2: Графики 2

Выводы по емкости аккумулятора для телефонов без Wi-Fi

```

1 1242.235294117647 - выборочное среднее
2 196128.43798148725 - выборочная дисперсия
3 1222.0 - выборочная медиана
4 1076.0 - выборочная квантиль порядка 2/5

```

Листинг 2.10: Вывод 3

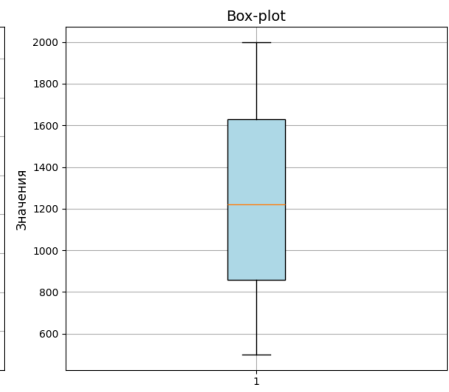



Рис. 2.3: Графики 3