

Министерство науки и высшего образования Российской
Федерации
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО
ОБРАЗОВАНИЯ «НАЦИОНАЛЬНЫЙ
ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ ИТМО»
(УНИВЕРСИТЕТ ИТМО)

ОТЧЕТ ПО ЛАБОРАТОРНОЙ РАБОТЕ №4

По дисциплине
«Математическая Статистика»
Вариант 2

Студенты:
Охрименко Ева
Даниил Буцкий

Проверил:
Шкваренко Андрей Алексеевич

г. Санкт-Петербург
2025

Оглавление

0.1 Вопрос

В этом задании нужно оценить однородность количества мужчин и женщин в эксперименте. Также нужно оценить этническую принадлежность. Вот код, который считает данные полов и данные этнических принадлежностей из файла:

```
1 f = open('exams_dataset.csv')
2
3 maleCount = femaleCount = 0
4 countA = countB = countC = countD = countE = 0
5
6 for line in f:
7
8     items = line.strip().replace('"', '').split(',')
9
10    gender = items[0]
11    ethnic = items[1]
12
13    if gender == 'male':
14        maleCount += 1
15    elif gender == 'female':
16        femaleCount += 1
17
18    if ethnic[-1] == 'A':
19        countA += 1
20    elif ethnic[-1] == 'B':
21        countB += 1
22    elif ethnic[-1] == 'C':
23        countC += 1
24    elif ethnic[-1] == 'D':
25        countD += 1
26    elif ethnic[-1] == 'E':
27        countE += 1
28
29
30 genderArray = list()
31 ethnicArray = list()
32
33 genderArray += [maleCount, femaleCount]
34 ethnicArray += [countA, countB, countC, countD, countE]
```

Листинг 1: Счет данных по выборкам

У нас получилось 506 мужчин и 494 женщин. Также у нас получился такой массив по этническим группам: [77, 204, 324, 261, 134]. Можно заметить, что массив с полами примерно однороден, а с этническими группами менее однороден.

0.1.1 Реализация методов

Для этого задания мы напомним 2 статистических метода на питоне. Метод хи-квадрат и метод вычисляющий критерий Когломорова-Смирнова

Итак, критерий хи-квадрат вычисляется по формуле:

$$\chi^2 = \sum_{i=1}^n \frac{(O_i - E_i)^2}{E_i}$$

где:

- O_i — наблюдаемые значения (элементы массива `array`)
- $E_i = \frac{\sum_{j=1}^n O_j}{n}$ — ожидаемое значение для равномерного распределения
- n — количество элементов в массиве (`ln = len(array)`)

А критерий Колмогорова-Смирнова вычисляется так:

$$D_n = \sup_x |F_n(x) - F(x)|$$

где:

- $F_n(x)$ — эмпирическая функция распределения:

$$F_n(x) = \frac{\text{количество элементов} \leq x}{n} = \frac{i}{n} \quad \text{для} \quad x \in [x_{(i)}, x_{(i+1)})$$

- $F(x)$ — теоретическая функция равномерного распределения:

$$F(x) = \frac{x}{\max(\text{array})} \quad \text{для} \quad x \in [0, \max(\text{array})]$$

- $\sup_x$ — супремум (максимальное отклонение)

Вот реализация кодом:

```
1 def hiQuad(array):
2
3     sm = sum(array)
4     ln = len(array)
5     expected = sm / ln
6
7     hiQuad = sum((i - expected)**2 / expected for i in array)
8
9     return round(hiQuad, 4)
```

Листинг 2: Расчет хи-квадрат

```

1 def kolmogorovSmirnov(array):
2
3     ln = len(array)
4     sortArray = np.sort(array)
5
6     y = np.arange(1, ln+1) / ln
7     teoria = sortArray / np.max(sortArray)
8     kriteriy = np.max(np.abs(y - teoria))
9
10    return round(kriteriy, 4)

```

Листинг 3: Расчет критерия Когломорова-Смирнова

0.1.2 Применение методов к выборкам

Применяем методы:

```

1 result = hiQuad(genderArray)
2 print(result)
3
4 Output >>> 0.144

```

Листинг 4: Применение метода к гендерам

```

1 result = kolmogorovSmirnov(ethnicArray)
2 print(result)
3
4 Output >>> 0.0377

```

Листинг 5: Применение метода к этникам

0.1.3 Оценка и вывод

Для начала сформулируем гипотезы для полов:

- Нулевая гипотеза: Распределение полов равномерное (50 на 50)
- Альтернативная гипотеза: Распределение полов неравномерное

Теперь посчитаем критическое значение хи квадрат по таблице из интернета

Критические точки распределения χ^2

Число степеней свободы, k	Уровень значимости α					
	0,01	0,025	0,05	0,95	0,975	0,99
1	6,6	5,0	3,8	0,0039	0,00098	0,00016
2	9,2	7,4	6,0	0,103	0,051	0,020
3	11,3	9,4	7,8	0,352	0,216	0,115
4	13,3	11,1	9,5	0,711	0,484	0,297
5	15,1	12,8	11,1	1,15	0,831	0,554
6	16,8	14,4	12,6	1,64	1,24	0,872
7	18,5	16,0	14,1	2,17	1,69	1,24
8	20,1	17,5	15,5	2,73	2,18	1,65
9	21,7	19,0	16,9	3,33	2,70	2,09
10	23,2	20,5	18,3	3,94	3,25	2,56
11	24,7	21,9	19,7	4,57	3,82	3,05
12	26,2	23,3	21,0	5,23	4,40	3,57
13	27,7	24,7	22,4	5,89	5,01	4,11
14	29,1	26,1	23,7	6,57	5,63	4,66
15	30,6	27,5	25,0	7,26	6,26	5,23
16	32,0	28,8	26,3	7,96	6,91	5,81
17	33,4	30,2	27,6	8,67	7,56	6,41
18	34,8	31,5	28,9	9,39	8,23	7,01
19	36,2	32,9	30,1	10,1	8,91	7,63
20	37,6	34,2	31,4	10,9	9,59	8,26
21	38,9	35,5	32,7	11,6	10,3	8,90
22	40,3	36,8	33,9	12,3	11,0	9,54
23	41,6	38,1	35,2	13,1	11,7	10,2
24	43,0	39,4	36,4	13,8	12,4	10,9
25	44,3	40,6	37,7	14,6	13,1	11,5
26	45,6	41,9	38,9	15,4	13,8	12,2
27	47,0	43,2	40,1	16,2	14,6	12,9
28	48,3	44,5	41,3	16,9	15,3	13,6
29	49,6	45,7	42,6	17,7	16,0	14,3
30	50,9	47,0	43,8	18,5	16,8	15,0

Рис. 1: Таблица

Нам нужно взять $k = 1$, так как оно считается по формуле $k = iterations - 1$ (посчитали по tutorialу) и возьмем $\alpha = 0.05$ - средний уровень значимости

Тогда наше критическое значение $\chi^2_{crit} = 3.8$. Так как $\chi^2_{crit} > \chi^2$, то вывод таков: распределение полов равномерное.

Теперь сформулируем гипотезы для этнических принадлежностей:

- Нулевая гипотеза: Распределение этник равномерное
- Альтернативная гипотеза: Распределение этник неравномерное

Для $\alpha = 0.0377$ и $n = 1000$:

$$D_{\text{крит}} = \frac{c(\alpha)}{\sqrt{n}} \approx \frac{1.47}{31.623} \approx 0.0465$$

где $c(0.0377) \approx 1.47$.

Так как $D_n = 0.123 > D_{\text{крит}} = 0.0465$, гипотеза H_0 о равномерном распределении не работает. Распределение неравномерно.

0.2 Вопрос

В этом задании нам нужно проверить гипотезу на однородность результатов по математике и письменной части. Создадим массив $[0] * 101$ куда будем записывать количество сдавших экзамен на i -тый балл, где i - индекс массива. Вот код:

```
1 f = open('exams_dataset.csv')
2
3 resultMath = [0] * 101
4 resultWrite = [0] * 101
5
6 continueCount = 0
7
8 for line in f:
9
10     continueCount += 1
11     if continueCount == 1:
12         continue
13
14     items = line.strip().replace('"', '').split(',')
15
16     resultMath[int(items[-3])] += 1
17     resultWrite[int(items[-1])] += 1
```

Листинг 6: Счет выборов

Теперь напишем статистические тесты. Возьмем уже готовые тесты хи-квадрат и Колгломорова-Смирнова. Проведем хи-квадрат для выборки `resultMath`:

```
1 obs = [x for x in resultMath if x > 0]
2 exp = [sum(obs)/len(obs)] * len(obs)
3
4 _, p = chisquare(obs, exp)
```


```

5 print("Неравномерное" if p < 0.05 else "Равномерное")
6
7 Output >>> Неравномерное

```

Листинг 7: χ^2 -тест

И действительно, данные неоднородны. Это можно заметить (даже без точных тестов) по распределению баллов:



Теперь проведем встроенный тест Колмогорова-Смирнова на выборке с результатами по письму.


```

1 obs = [x for x in resultWrite if x > 0]
2 exp = [sum(obs)/len(obs)] * len(obs)
3
4 ks_stat, ks_p = stats.kstest(obs, 'uniform', args=(min(obs), max(obs) -
5 min(obs)))
6 print("Неравномерное" if ks_p < 0.05 else "Равномерное")
7 Output >>> Неравномерное

```

Листинг 8: K-S тест

Также посмотрим на распределение баллов и убедимся в правильности теста:



0.3 Вопрос

Верно ли, что прошедшие подготовительные курсы студенты лучше сдали экзамены?

0.3.1 Формализация гипотез:

H_0 : Нет различий в средних баллах по математике между теми, кто посещал подготовительные курсы, и теми, кто их не посещал.

H_1 : Те, кто прошёл подготовительные курсы, лучше сдали математику (средний балл выше).

0.3.2 Проверка гипотезы

Шаг 1. Объединение и ранжирование

- Объединяем все значения из обеих групп в один массив.
- Сортируем этот массив по возрастанию.
- Каждому элементу присваиваем ранг: самое маленькое значение - ранг 1, следующее - 2 и т.д.
- Если встречаются одинаковые значения (тай), им присваивается средний ранг для их позиций.

Шаг 2. Сумма рангов по группам

Считаем сумму рангов для первой группы (R_1) и второй группы (R_2).

Шаг 3. Вычисление U-статистики

Для каждой группы считается своё значение U :

$$U_1 = R_1 - \frac{n_1(n_1 + 1)}{2}$$

$$U_2 = R_2 - \frac{n_2(n_2 + 1)}{2}$$

U_1 - число случаев, когда значение из первой группы больше значения из второй.

U_2 - наоборот.

Обычно для теста берут минимальное из этих двух значений.

Шаг 4. Подсчет вероятности (p-value)

$$\mu_U = \frac{n_1 n_2}{2}$$

$$\sigma_U = \sqrt{\frac{n_1 n_2 (n_1 + n_2 + 1)}{12}}$$

$$Z = \frac{U - \mu_U}{\sigma_U}$$

Z - стандартная нормальная статистика.

p -value - вероятность получить $|Z|$ или большее значение по стандартному нормальному распределению (двусторонний тест).

Я решил провести тесты с помощью U-критерия Манна-Уитни, потому что распределение ненормальное. Один тест я буду проводить с помощью теста из библиотеки, а другой написанный вручную.

Вот код, который делает это:

```
1 import pandas as pd
2 import matplotlib.pyplot as plt
3 import seaborn as sns
4 from scipy.stats import mannwhitneyu, norm
5 import numpy as np
6 from scipy.stats import norm
7
8 # Загрузка данных
9 df = pd.read_csv('exams_dataset.csv')
10
11 # Создаем суммарный балл по трём экзаменам
12 df['total_score'] = df['math score'] + df['reading score'] + df['writing
    score']
13
14 # Разделение на группы
```

```

15 completed = df[df['test preparation course'] == 'completed']['total_score'
16 ]
17 none = df[df['test preparation course'] == 'none']['total_score']
18
19 # --- Тест 1: Манн-Уитни с библиотекой ---
20 stat, p_lib = mannwhitneyu(completed, none, alternative='greater')
21 print(f"Библиотечный Mann-Whitney U test:\nU={stat:.0f}, p={p_lib:.6e}")
22
23 # --- Тест 2: Собственная реализация Манн-Уитни U-теста ---
24 def mannwhitneyu_manual(x, y):
25     # Сортируем объединённые значения и присваиваем ранги
26     all_values = np.concatenate([x, y])
27     ranks = pd.Series(all_values).rank(method='average').values
28     # Ранги для первой группы
29     ranks_x = ranks[:len(x)]
30     # Сумма рангов первой группы
31     R1 = ranks_x.sum()
32     n1 = len(x)
33     n2 = len(y)
34     # U-статистика для первой группы
35     U1 = R1 - n1 * (n1 + 1) / 2
36     # U-статистика для второй группы по определению
37     U2 = n1 * n2 - U1
38     U = min(U1, U2)
39
40     mu_U = n1 * n2 / 2
41     sigma_U = np.sqrt(n1 * n2 * (n1 + n2 + 1) / 12)
42     z = (U - mu_U) / sigma_U
43     # Двусторонний p-value
44     p_manual = 2 * norm.cdf(-abs(z))
45     return U, p_manual
46
47 U_man, p_man = mannwhitneyu_manual(completed, none)
48 print(f"Ручной Mann-Whitney U test:\nU={U_man:.0f}, p={p_man:.6e}")
49
50 # --- Визуализация: только violin plot ---
51 plt.figure(figsize=(8, 6))
52 sns.violinplot(x='test preparation course', y='total_score', data=df,
53               inner="quartile", split=True)
54 plt.title('Плотность распределения суммарных баллов по экзаменам\нзависимости от
55           прохождения подготовительных курсов')
56 plt.xlabel('Подготовительные курсы')
57 plt.ylabel('Суммарный балл')
58 plt.tight_layout()
59 plt.show()

```

Листинг 9: K-S тест

Вывод программы:

tex/3_2.png

Вывод ручного и автоматического теста отличается, потому что в автоматической функции, выводится значения для первой выборки, а в ручном выводится минимальное значение U между двумя выборками. U_1 почти в 2 раза больше, чем U_2 , что также подтверждает, что в большинстве случаев, люди, прошедшие подготовительные курсы сдают лучше.

Оба теста Манна–Уитни (библиотечный и ручной) показали крайне малое p -value ($p \ll 0.05$), что позволяет с высокой уверенностью утверждать: прошедшие подготовительные курсы сдают экзамены лучше, чем не прошедшие.

Также рассмотрим распределение 2 типов студентов, чтобы наглядно увидеть, что факт прохождения подготовительных курсов, является значимым:

tex/3_1.png