

Министерство науки и высшего образования Российской
Федерации
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО
ОБРАЗОВАНИЯ «НАЦИОНАЛЬНЫЙ
ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ ИТМО»
(УНИВЕРСИТЕТ ИТМО)

ОТЧЕТ ПО ЛАБОРАТОРНОЙ РАБОТЕ №4

По дисциплине
«Математическая Статистика»
Вариант 2

Студенты:
Охрименко Ева
Даниил Буцкий

Проверил:
Шкваренко Андрей Алексеевич

г. Санкт-Петербург
2025

Оглавление

0.1	Task 1		2
0.2	Task 2		7

0.1 Task 1

Постановка задачи Необходимо построить линейную модель вида:

$$\text{mobile_wt} = \beta_0 + \beta_1 \cdot \text{sc_h} + \beta_2 \cdot \text{sc_w} + \beta_3 \cdot \text{battery_power} + \epsilon, \quad (1)$$

где:

- mobile_wt — зависимая переменная (вес телефона, в граммах),
- sc_h , sc_w , battery_power — независимые переменные (высота экрана, ширина экрана, ёмкость аккумулятора),
- $\beta_0, \beta_1, \beta_2, \beta_3$ — коэффициенты модели,
- ϵ — случайная ошибка

Требуется:

1. Оценить коэффициенты $\beta_0, \beta_1, \beta_2, \beta_3$ методом наименьших квадратов (МНК).
2. Вычислить остаточную дисперсию $\hat{\sigma}^2$.
3. Построить доверительные интервалы для коэффициентов.
4. Вычислить коэффициент детерминации R^2 .
5. Проверить гипотезы:
 - Чем больше высота экрана, тем больше масса ($H_{01}: \beta_1 > 0$).
 - Чем больше ширина экрана, тем больше масса ($H_{02}: \beta_2 > 0$).
 - $H_0: \beta_2 = \beta_3 = 0$ против H_1 : хотя бы один из $\beta_2, \beta_3 \neq 0$.

Метод наименьших квадратов (МНК)

Для оценки коэффициентов используем МНК. Считаем сумму квадратов остатков.

$$\text{RSS} = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \sum_{i=1}^n (y_i - (\beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \beta_3 x_{i3}))^2, \quad (2)$$

где $y_i = \text{mobile_wt}_i$, $x_{i1} = \text{sc_h}_i$, $x_{i2} = \text{sc_w}_i$, $x_{i3} = \text{battery_power}_i$.

В матричной форме модель записывается как:

$$\mathbf{y} = \mathbf{X}\beta + \epsilon, \quad (3)$$

где:

- $\mathbf{y}$ — вектор $n \times 1$ значений mobile_wt,
- $\mathbf{X}$ — матрица $n \times (k + 1)$ (где $k = 3$ — число независимых переменных), первый столбец — единицы (для β_0),
- $\beta = [\beta_0, \beta_1, \beta_2, \beta_3]^T$ — вектор коэффициентов,
- ϵ — вектор ошибок.

Оценка $\hat{\beta}$ находится как:

$$\hat{\beta} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}. \quad (4)$$

Остаточная дисперсия

Остаточная дисперсия $\hat{\sigma}^2$ оценивается как:

$$\hat{\sigma}^2 = \frac{\text{RSS}}{n - k - 1} = \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{n - k - 1}, \quad (5)$$

где $\hat{y}_i = \mathbf{x}_i^T \hat{\beta}$, n — число наблюдений, k — число независимых переменных ($k = 3$).

Доверительные интервалы для коэффициентов

Для каждого коэффициента $\hat{\beta}_j$ доверительный интервал на уровне значимости $\alpha = 0.05$ строится как:

$$\hat{\beta}_j \pm t_{1-\alpha/2, n-k-1} \cdot \text{se}(\hat{\beta}_j), \quad (6)$$

где:

- $t_{1-\alpha/2, n-k-1}$ — квантиль t -распределения с $n - k - 1$ степенями свободы (для $\alpha = 0.05$, это примерно 1.96 для больших n),
- $\text{se}(\hat{\beta}_j) = \sqrt{\hat{\sigma}^2 \cdot (\mathbf{X}^T \mathbf{X})_{jj}^{-1}}$ — стандартная ошибка коэффициента, где $(\mathbf{X}^T \mathbf{X})_{jj}^{-1}$ — j -й диагональный элемент матрицы $(\mathbf{X}^T \mathbf{X})^{-1}$.

Коэффициент детерминации R^2

Коэффициент детерминации:

$$R^2 = 1 - \frac{\text{RSS}}{\text{TSS}}, \quad (7)$$

где $\text{TSS} = \sum (y_i - \bar{y})^2$ — общая сумма квадратов, $\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i$.

Проверка гипотез

1. H_{01} : Чем больше высота экрана, тем больше масса ($\beta_1 > 0$). Проверяем с помощью t -теста: $t = \frac{\hat{\beta}_1}{se(\hat{\beta}_1)}$. Если $t > t_{1-\alpha, n-k-1}$, гипотеза подтверждается.
2. H_{02} : Чем больше ширина экрана, тем больше масса ($\beta_2 > 0$). Аналогично: $t = \frac{\hat{\beta}_2}{se(\hat{\beta}_2)}$.
3. H_0 : $\beta_2 = \beta_3 = 0$ против H_1 : хотя бы один $\beta_2, \beta_3 \neq 0$. Используем F -тест:
 - Полная модель: $mobile_wt = \beta_0 + \beta_1 \cdot sc_h + \beta_2 \cdot sc_w + \beta_3 \cdot battery_power$.
 - Сокращённая модель (при H_0): $mobile_wt = \beta_0 + \beta_1 \cdot sc_h$.
 - F -статистика:

$$F = \frac{(RSS_{\text{сокращённая}} - RSS_{\text{полная}})/q}{RSS_{\text{полная}}/(n - k - 1)}, \quad (8)$$

где $q = 2$ (число ограничений: $\beta_2 = 0, \beta_3 = 0$). Сравниваем с критическим значением $F_{q, n-k-1}$.

```

1 import numpy as np
2 from scipy.stats import t, f
3 import pandas as pd
4
5 # Шаг 1: Загрузка данных предполагаем(, что файл доступен)
6 # Здесь я использую первые 2000 строк из mobile_phones.csv
7 data = pd.read_csv('mobile_phones.csv')
8 X = data[['sc_h', 'sc_w', 'battery_power']].values[:2000]
9 y = data['mobile_wt'].values[:2000]
10 n, k = X.shape[0], X.shape[1] # n = 2000, k = 3
11
12 # Добавляем столбец единиц для свободного члена
13 X = np.hstack([np.ones((n, 1)), X]) # Теперь X: 2000 x 4
14
15 # Шаг 2: Оценка коэффициентов МНК()
16 XTX = np.dot(X.T, X)
17 XTX_inv = np.linalg.inv(XTX)
18 XTy = np.dot(X.T, y)
19 beta_hat = np.dot(XTX_inv, XTy)
20 print("Оценки коэффициентов (beta_0, beta_1, beta_2, beta_3):", beta_hat)
21
22 # Шаг 3: Остатки и остаточная дисперсия
23 y_hat = np.dot(X, beta_hat)
24 residuals = y - y_hat
25 RSS = np.sum(residuals**2)
26 sigma2_hat = RSS / (n - k - 1)
27 print("Остаточная дисперсия:", sigma2_hat)
28
29 # Шаг 4: Доверительные интервалы
30 # Стандартные ошибки
31 C = XTX_inv # Ковариационная матрица

```

```

32 se_beta = np.sqrt(sigma2_hat * np.diag(C))
33 # Квантиль t-распределения для alpha = 0.05, df = 496
34 t_quantile = t.ppf(0.975, df=n-k-1)
35 conf_intervals = [(beta_hat[j] - t_quantile * se_beta[j], beta_hat[j] +
36     t_quantile * se_beta[j]) for j in range(len(beta_hat))]
37
38 # Шаг 5: Коэффициент детерминации
39 y_mean = np.mean(y)
40 TSS = np.sum((y - y_mean)**2)
41 R2 = 1 - RSS / TSS
42 print("Коэффициент детерминации R^2:", R2)
43
44 # Шаг 6: Проверка гипотез
45 # 6.1: H_01: beta_1 > 0 Чем (больше высота экрана, тем больше масса)
46 t_stat1 = beta_hat[1] / se_beta[1]
47 p_value1 = 1 - t.cdf(t_stat1, df=n-k-1) # Односторонний тест
48 print("t-статистика для beta_1:", t_stat1, "p-значение-:", p_value1)
49
50 # 6.2: H_02: beta_2 > 0 Чем (больше ширина экрана, тем больше масса)
51 t_stat2 = beta_hat[2] / se_beta[2]
52 p_value2 = 1 - t.cdf(t_stat2, df=n-k-1)
53 print("t-статистика для beta_2:", t_stat2, "p-значение-:", p_value2)
54
55 # 6.3: H_0: beta_2 = beta_3 = 0
56 # Сокращённая модель: mobile_wt = beta_0 + beta_1 * sc_h
57 X_reduced = X[:, [0, 1]] # Только beta_0 и beta_1
58 XTX_reduced = np.dot(X_reduced.T, X_reduced)
59 XTX_reduced_inv = np.linalg.inv(XTX_reduced)
60 XT_y_reduced = np.dot(X_reduced.T, y)
61 beta_reduced = np.dot(XTX_reduced_inv, XT_y_reduced)
62 y_hat_reduced = np.dot(X_reduced, beta_reduced)
63 residuals_reduced = y - y_hat_reduced
64 RSS_reduced = np.sum(residuals_reduced**2)
65
66 # F-статистика
67 q = 2 # Число ограничений (beta_2 = 0, beta_3 = 0)
68 F_stat = ((RSS_reduced - RSS) / q) / (RSS / (n - k - 1))
69 p_value_F = 1 - f.cdf(F_stat, dfn=q, dfd=n-k-1)
70 print("F-статистика для H_0: beta_2 = beta_3 = 0:", F_stat, "p-значение-:",
    p_value_F)

```

Листинг 1: Инициализация массивов с баллами

```

C:\Users\danya\pythonProject5\venv\Scripts\python.exe C:/Users/danya/pythonProject5/lab5_matstat.py
Оценки коэффициентов (beta_0, beta_1, beta_2, beta_3): [143.640572, -0.263548, -0.039549, 0.000064]
Оценка остаточной дисперсии: 35.405616
Доверительные интервалы для коэффициентов: [(137.050031, 150.231113), (-0.691046, 0.163950), (-0.452908, 0.373811), (-0.003471, 0.003600)]
Коэффициент детерминации R^2: 0.0011644496581527664
t-статистика для beta_1: -1.2090313328631839 p-значение: 0.8866029986025021
t-статистика для beta_2: -0.18763547736466002 p-значение: 0.5744092575407408
F-статистика для H_0: beta_2 = beta_3 = 0: 0.018292704595014697 p-значение: 0.9818737559867448

```

Анализ вывода программы

Оценки коэффициентов $(\beta_0, \beta_1, \beta_2, \beta_3)$: [143.640572, -0.263548, -0.039549, 0.000064]

- $\hat{\beta}_0 = 143.640572$: Свободный член. Теоретическая масса телефона (в граммах), когда $sc_h = 0$, $sc_w = 0$, $battery_power = 0$. Значение 143.64 грамма выглядит реалистично как базовая масса телефона без учёта экрана и аккумулятора, хотя в реальности такие условия маловероятны.
- $\hat{\beta}_1 = -0.263548$: Коэффициент при sc_h (высота экрана). Указывает, что увеличение высоты экрана на 1 дюйм уменьшает массу телефона на 0.263548 грамма при фиксированных sc_w и $battery_power$. Отрицательное значение противоречит гипотезе $H_{01} : \beta_1 > 0$, но может отражать использование лёгких материалов в телефонах с большими экранами.
- $\hat{\beta}_2 = -0.039549$: Коэффициент при sc_w (ширина экрана). Увеличение ширины на 1 дюйм уменьшает массу на 0.039549 грамма при фиксированных sc_h и $battery_power$. Эффект слабый и также отрицательный, что противоречит $H_{02} : \beta_2 > 0$.
- $\hat{\beta}_3 = 0.000064$: Коэффициент при $battery_power$ (ёмкость аккумулятора). Увеличение ёмкости на 1 мА·ч увеличивает массу на 0.000064 грамма, что эквивалентно 0.064 грамма на 1000 мА·ч. Это положительное значение логично, но эффект очень мал.

Оценка остаточной дисперсии: 35.405616

Остаточная дисперсия $\hat{\sigma} = 35.405616$ показывает средний квадрат ошибки модели. Стандартное отклонение остатков:

$$\hat{\sigma} = 35.405616, \text{ грамма.} \quad (9)$$

Предсказания массы отклоняются от реальных значений в среднем на ± 35.405616 грамма, что составляет значительную часть от диапазона 80–200 граммов.

Доверительные интервалы для коэффициентов: [(137.050031, 150.231113), (-0.691046, 0.163950), (-0.452908, 0.373811), (-0.003471, 0.003600)]

- β_0 : (137.050031, 150.231113): Интервал включает 143.64, что нормально. Указывает на возможный диапазон базовой массы (137–150 граммов).
- β_1 : (-0.691046, 0.163950): Интервал включает 0, что подтверждает, что β_1 статистически незначим. Отрицательное значение $\hat{\beta}_1 = -0.263548$ находится внутри интервала.
- β_2 : (-0.452908, 0.373811): Также включает 0, и $\hat{\beta}_2 = -0.039549$ внутри. Эффект sc_w незначим.

- β_3 : $(-0.003471, 0.003600)$: Включает 0, и $\hat{\beta}_3 = 0.000064$ внутри. Эффект `battery_power` незначим, несмотря на положительное значение.

Коэффициент детерминации R^2 : 0.0011644496581527664

$R^2 \approx 0.00116$ означает, что модель объясняет только 0.116% вариации `mobile_wt`. Это крайне низкое значение, указывающее на то, что переменные `sc_h`, `sc_w` и `battery_power` практически не влияют на массу телефона.

t -статистика для β_1 : -1.2090313328631839, p -значение: 0.8866029986025021

- Анализ: Отрицательная t -статистика ($t = -1.209$) указывает на $\hat{\beta}_1 < 0$. p -значение 0.8866 (для одностороннего теста $H_{01} : \beta_1 > 0$) значительно больше 0.05, поэтому H_{01} отвергается. Нет доказательств, что высота экрана увеличивает массу; эффект незначим.

t -статистика для β_2 : -0.18763547736466002, p -значение: 0.5744092575407408

- Анализ: $t = -0.1876$ (отрицательное) и $p = 0.5744$ (для $H_{02} : \beta_2 > 0$) также больше 0.05. H_{02} отвергается. Ширина экрана не увеличивает массу, и эффект незначим.

F -статистика для $H_0 : \beta_2 = \beta_3 = 0$: 0.018292704595014697, p -значение: 0.9818737559867448

- Анализ: F -тест проверяет, значимы ли β_2 и β_3 одновременно. $F = 0.018$ очень мало, а $p = 0.9819 \gg 0.05$. Это означает, что мы не можем отвергнуть $H_0 : \beta_2 = \beta_3 = 0$. Переменные `sc_w` и `battery_power` не вносят значимого вклада в модель.

0.2 Task 2

В этом задании нужно определить, влияет ли национальность студентов на их общий балл за экзамены. Другими словами — есть ли группы, которые сдают экзамены статистически значимо лучше или хуже других.

Для начала создадим несколько массивов инициализированных по этническому признаку. И засунем туда суммарные баллы студентов именно этой национальности. Вот код, реализующий это:

```
1 f = open('exams_dataset.csv')
2
3 countA = []
4 countB = []
```

```

5 countC = []
6 countD = []
7 countE = []
8 continueCount = 0
9
10 for line in f:
11
12     continueCount += 1
13     if continueCount == 1:
14         continue
15
16     items = line.strip().replace('"', '').split(',')
17
18     ethnic = items[1]
19     points = sum(map(int, items[-3:]))
20
21     if ethnic[-1] == 'A':
22         countA.append(points)
23     elif ethnic[-1] == 'B':
24         countB.append(points)
25     elif ethnic[-1] == 'C':
26         countC.append(points)
27     elif ethnic[-1] == 'D':
28         countD.append(points)
29     elif ethnic[-1] == 'E':
30         countE.append(points)

```

Листинг 2: Инициализация массивов с баллами

Для того, чтобы сделать модель однофакторного дисперсионного анализа нам надо найти:

- μ — общее среднее по всем группам
- SSB — сумма квадратов между группами
- SSW — сумма квадратов внутри групп
- степени свободы
- F-статистику
- критическое значение F_{crit} , чтобы сравнить с F

Итак, начнем. Для начала рассчитаем общее среднее по всем группам:

$$\mu = \frac{\sum_{i=1}^k \sum_{j=1}^{n_i} Y_{ij}}{N}$$

```

1 allScores = countA + countB + countC + countD + countE
2 mu = sum(allScores) / len(allScores)

```

Листинг 3: mean по всем группам

```
mu = 202.404
```

Теперь найдем SSB:

$$SSB = \sum_{i=1}^k n_i (\bar{Y}_i - \mu)^2$$

```

1 groupMeans = [
2     sum(countA)/len(countA),
3     sum(countB)/len(countB),
4     sum(countC)/len(countC),
5     sum(countD)/len(countD),
6     sum(countE)/len(countE)
7 ]
8
9 groupSizes = [len(countA), len(countB), len(countC), len(countD), len(
10    countE)]
11
12 SSB = sum(
13     n * (groupMean - mu) ** 2
14     for n, groupMean in zip(groupSizes, groupMeans)
15 )

```

Листинг 4: SSB

```
SSB ≈ 112381.64
```

Рассчитаем SSW:

$$SSW = \sum_{i=1}^k \sum_{j=1}^{n_i} (Y_{ij} - \bar{Y}_i)^2$$

```

1 groups = [countA, countB, countC, countD, countE]
2 SSW = 0.0
3 for group, mean in zip(groups, groupMeans):
4     for score in group:
5         SSW += (score - mean) ** 2

```

Листинг 5: SSW

```
SSW ≈ 1953413.14
```

Теперь посчитаем степени свободы:

$$df_{total} = N - 1$$

$$df_{between} = k - 1$$

$$df_{within} = N - k$$

Где:

- N - общее количество наблюдений
- k - количество групп
- df_{total} - общие степени свободы
- $df_{between}$ - степени свободы между группами
- df_{within} - степени свободы внутри групп

```

1 N = sum(len(group) for group in groups)
2 k = len(groups)
3
4 dfTotal = N - 1
5 dfBetween = k - 1
6 dfWithin = N - k

```

Листинг 6: Степени свободы

```

dfTotal = 999
dfBetween = 4
dfWithin = 995

```

Далее посчитаем F-статистику

$$F = \frac{MSB}{MSW},$$

Где:

- $MSB = \frac{SSB}{df_{between}}$
- $MSW = \frac{SSW}{df_{within}}$

```

1 MSB = SSB / dfBetween
2 MSW = SSW / dfWithin
3 F = MSB / MSW

```

Листинг 7: F-статистика

$$F \approx 14.31$$

Теперь найдем `F_crit` кодом. Возьмем $\alpha = 0.05$ - стандартный уровень значимости.

```
1 alpha = 0.05
2 F_crit = f.ppf(1 - alpha, dfBetween, dfWithin)
```

Листинг 8: F-статистика

$$F_{crit} \approx 2.38$$

Итог:

В результате однофакторного дисперсионного анализа получилось

$$F > F_{crit}.$$

Это означает, что количество баллов статистически зависимо от национальности.