

Министерство науки и высшего образования Российской
Федерации
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО
ОБРАЗОВАНИЯ «НАЦИОНАЛЬНЫЙ
ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ ИТМО»
(УНИВЕРСИТЕТ ИТМО)

ОТЧЕТ ПО ЛАБОРАТОРНОЙ РАБОТЕ №4

По дисциплине
«Математическая Статистика»
Вариант 2

Студенты:
Охрименко Ева
Даниил Буцкий

Проверил:
Шкваренко Андрей Алексеевич

г. Санкт-Петербург
2025

Оглавление

0.1	Task 1		2
0.2	Task 2		2

0.1 Task 1

0.2 Task 2

В этом задании нужно определить, влияет ли национальность студентов на их общий балл за экзамены. Другими словами — есть ли группы, которые сдают экзамены статистически значимо лучше или хуже других.

Для начала создадим несколько массивов инициализированных по этническому признаку. И засунем туда суммарные баллы студентов именно этой национальности. Вот код, реализующий это:

```
1  f = open('exams_dataset.csv')
2
3  countA = []
4  countB = []
5  countC = []
6  countD = []
7  countE = []
8  continueCount = 0
9
10 for line in f:
11
12     continueCount += 1
13     if continueCount == 1:
14         continue
15
16     items = line.strip().replace('"', '').split(',')
17
18     ethnic = items[1]
19     points = sum(map(int, items[-3:]))
20
21     if ethnic[-1] == 'A':
22         countA.append(points)
23     elif ethnic[-1] == 'B':
24         countB.append(points)
25     elif ethnic[-1] == 'C':
26         countC.append(points)
27     elif ethnic[-1] == 'D':
28         countD.append(points)
29     elif ethnic[-1] == 'E':
30         countE.append(points)
```

Листинг 1: Инициализация массивов с баллами

Для того, чтобы сделать модель однофакторного дисперсионного анализа нам надо найти:

- μ — общее среднее по всем группам
- SSB — сумма квадратов между группами

- SSW — сумма квадратов внутри групп
- степени свободы
- F-статистику
- критическое значение `F_crit`, чтобы сравнить с F

Итак, начнем. Для начала рассчитаем общее среднее по всем группам:

$$\mu = \frac{\sum_{i=1}^k \sum_{j=1}^{n_i} Y_{ij}}{N}$$

```
1 allScores = countA + countB + countC + countD + countE
2 mu = sum(allScores) / len(allScores)
```

Листинг 2: mean по всем группам

```
mu = 202.404
```

Теперь найдем SSB:

$$SSB = \sum_{i=1}^k n_i (\bar{Y}_i - \mu)^2$$

```
1 groupMeans = [
2     sum(countA)/len(countA),
3     sum(countB)/len(countB),
4     sum(countC)/len(countC),
5     sum(countD)/len(countD),
6     sum(countE)/len(countE)
7 ]
8
9 groupSizes = [len(countA), len(countB), len(countC), len(countD), len(
10    countE)]
11
12 SSB = sum(
13     n * (groupMean - mu) ** 2
14     for n, groupMean in zip(groupSizes, groupMeans)
15 )
```

Листинг 3: SSB

```
SSB ≈ 112381.64
```

Рассчитаем SSW:

$$SSW = \sum_{i=1}^k \sum_{j=1}^{n_i} (Y_{ij} - \bar{Y}_i)^2$$

```

1 groups = [countA, countB, countC, countD, countE]
2 SSW = 0.0
3 for group, mean in zip(groups, groupMeans):
4     for score in group:
5         SSW += (score - mean) ** 2

```

Листинг 4: SSW

SSW $\approx$ 1953413.14

Теперь посчитаем степени свободы:

$$\begin{aligned}
 df_{total} &= N - 1 \\
 df_{between} &= k - 1 \\
 df_{within} &= N - k
 \end{aligned}$$

Где:

- N - общее количество наблюдений
- k - количество групп
- df_{total} - общие степени свободы
- $df_{between}$ - степени свободы между группами
- df_{within} - степени свободы внутри групп

```

1 N = sum(len(group) for group in groups)
2 k = len(groups)
3
4 dfTotal = N - 1
5 dfBetween = k - 1
6 dfWithin = N - k

```

Листинг 5: Степени свободы

```

dfTotal = 999
dfBetween = 4
dfWithin = 995

```

Далее посчитаем F-статистику

$$F = \frac{MSB}{MSW},$$

Где:

- $MSB = \frac{SSB}{df_{between}}$
- $MSW = \frac{SSW}{df_{within}}$

```
1 MSB = SSB / dfBetween
2 MSW = SSW / dfWithin
3 F = MSB / MSW
```

Листинг 6: F-статистика

$F \approx 14.31$

Теперь найдем **F_crit** кодом. Возьмем $\alpha = 0.05$ - стандартный уровень значимости.

```
1 alpha = 0.05
2 F_crit = f.ppf(1 - alpha, dfBetween, dfWithin)
```

Листинг 7: F-статистика

$F_{crit} \approx 2.38$

Итог:

В результате однофакторного дисперсионного анализа получилось

$$F > F_{crit}.$$

Это означает, что количество баллов зависит от национальности.